



Module : Séries Chronologiques

Encadré par : Mme Badaoui

Application de la méthode de Box-Jenkins

Prévision des ventes mensuelles de voitures au Québec

Réalisé par :

Ait Bargach Ahmed

Année universitaire 2025–2026

Résumé

Ce rapport reprend le contenu du notebook `notebook_box_jenkins.ipynb`. L'objectif est d'appliquer la méthode de Box-Jenkins à la série des ventes mensuelles de voitures au Québec entre janvier 1960 et décembre 1968. La série est séparée en un échantillon d'apprentissage, de janvier 1960 à décembre 1966, et un échantillon de validation, de janvier 1967 à décembre 1968. Après analyse de la tendance, de la saisonnalité et de la stationnarité, le notebook retient le modèle $\text{SARIMA}(1, 1, 1)(1, 1, 1)_{12}$. Sur la période de validation, ce modèle donne une erreur absolue moyenne de 1191 ventes, une RMSE de 1339 ventes et un MAPE de 5,64 %, ce qui indique une bonne qualité de prévision.

1 Introduction

Une série chronologique est une suite d'observations ordonnées dans le temps. Dans ce projet, on cherche à construire un modèle permettant de prévoir les ventes mensuelles de voitures. La démarche suivie est celle de Box-Jenkins : visualisation de la série, séparation apprentissage-validation, analyse qualitative, tests de stationnarité, étude des corrélogrammes, estimation d'un modèle SARIMA, validation des résidus et évaluation des prévisions.

Le rapport suit la même organisation que le notebook :

1. chargement et visualisation des données ;
2. division apprentissage / validation ;
3. analyse qualitative ;
4. tests de stationnarité ;
5. corrélogrammes ACF et PACF ;
6. méthode de Box-Jenkins ;
7. prévision sur l'échantillon de validation ;
8. évaluation des performances.

2 Chargement des données et visualisation

La série utilisée contient les ventes mensuelles de voitures au Québec entre janvier 1960 et décembre 1968. Elle comporte 108 observations mensuelles. Les données sont chargées depuis le fichier `car_sales.csv`, puis l'indice temporel est converti en dates mensuelles.

Statistique	Valeur
Nombre d'observations	108
Moyenne	15 396
Écart-type	5 452
Minimum	6 550
Premier quartile	11 300
Médiane	14 494
Troisième quartile	18 152
Maximum	29 500

TABLE 1 – Statistiques descriptives des ventes mensuelles.

La figure 1 montre une tendance croissante sur la période. On observe aussi des mouvements qui se répètent chaque année, ce qui laisse penser à une saisonnalité annuelle.




FIGURE 1 – Ventes mensuelles de voitures au Québec entre 1960 et 1968.

3 Division apprentissage / validation

Comme dans le notebook, on réserve les 24 dernières observations, soit les deux dernières années, pour la validation. Le modèle est donc construit sur les données de janvier 1960 à décembre 1966, puis testé sur les données de janvier 1967 à décembre 1968.

Échantillon	Période	Taille
Apprentissage	Janvier 1960 - Décembre 1966	84
Validation	Janvier 1967 - Décembre 1968	24

TABLE 2 – Découpage utilisé dans le notebook.




FIGURE 2 – Découpage entre apprentissage et validation.

4 Analyse qualitative de la série

La décomposition est réalisée sur l'échantillon d'apprentissage. On utilise une décomposition multiplicative, car l'amplitude des variations saisonnières augmente avec le niveau de la série. On considère donc une écriture de la forme :

$$Y_t = T_t \times S_t \times R_t,$$

où T_t représente la tendance, S_t la composante saisonnière et R_t le résidu.




FIGURE 3 – Décomposition multiplicative de l'échantillon d'apprentissage.

L'interprétation du notebook est la suivante :

- la tendance est globalement croissante ;
- la saisonnalité est marquée, avec un pic au printemps, surtout en avril-mai ;
- le résidu fluctue autour de 1, ce qui est cohérent avec une décomposition multiplicative.

La visualisation par mois confirme cette saisonnalité. Les ventes sont plus fortes au printemps et diminuent généralement au début de l'année et vers la fin de l'année.




FIGURE 4 – Profil saisonnier par année.

5 Test de stationnarité

Le notebook applique deux tests :

- le test ADF, dont l'hypothèse nulle est la non-stationnarité;
- le test KPSS, dont l'hypothèse nulle est la stationnarité.

La série brute n'est pas stationnaire. La transformation logarithmique seule ne suffit pas. Après différenciation ordinaire, la série devient stationnaire selon les deux tests. On garde aussi la différenciation saisonnière afin de construire un modèle SARIMA avec $d = 1$, $D = 1$ et une période saisonnière $s = 12$.

Série testée	p-value ADF	p-value KPSS
Série brute	0,9886	0,0100
$\log(Y_t)$	0,7168	0,0100
$\Delta \log(Y_t)$	0,0002	0,1000
$\Delta_{12} \log(Y_t)$	0,3437	0,1000
$\Delta \Delta_{12} \log(Y_t)$	0,0089	0,1000

TABLE 3 – Tests ADF et KPSS réalisés dans le notebook.




FIGURE 5 – Série brute, logarithme et série stationnaire.

6 Corrélogrammes ACF et PACF

Les corrélogrammes sont tracés sur la série stationnaire. On utilise les retards jusqu'à 40 pour l'ACF et jusqu'à 30 pour la PACF, ce qui respecte l'idée d'avoir un décalage d'ordre au moins égal à 36 pour l'ACF.

La lecture proposée est la suivante : l'ACF et la PACF indiquent la présence de composantes autorégressives et moyenne mobile. Les pics aux retards 12 et 24 confirment la saisonnalité annuelle.




FIGURE 6 – Corrélogrammes ACF et PACF de la série stationnaire.

7 Méthode de Box-Jenkins : modèle SARIMA

La série présente une saisonnalité de période 12. on cherche donc un modèle :

$$SARIMA(p, 1, q)(P, 1, Q)_{12}.$$

Les ordres sont testés sur une petite grille :

$$p, q \in \{0, 1, 2\}, \quad P, Q \in \{0, 1\}.$$

Le critère de sélection utilisé est l'AIC. Le meilleur modèle obtenu dans le notebook est :

$$SARIMA(1, 1, 1)(1, 1, 1)_{12},$$

avec un AIC de $-248,98$.

Rang	p	d	q	P	D	Q	AIC
1	1	1	1	1	1	1	-248,98
2	0	1	2	1	1	0	-248,81
3	2	1	2	0	1	0	-248,57
4	1	1	0	0	1	0	-248,11
5	1	1	2	0	1	0	-247,36

TABLE 4 – Cinq meilleurs modèles selon l'AIC.

Le modèle retenu peut s'écrire, sur la série logarithmique :

$$(1 - \phi_1 B)(1 - \Phi_1 B^{12})(1 - B)(1 - B^{12}) \log(Y_t) = (1 + \theta_1 B)(1 + \Theta_1 B^{12}) \varepsilon_t.$$

8 Validation des résidus

Après estimation, le notebook trace les diagnostics des résidus. L'objectif est de vérifier que les résidus ressemblent à un bruit blanc : pas de structure visible, histogramme raisonnablement centré, QQ-plot proche de la diagonale et ACF des résidus sans pics importants.




FIGURE 7 – Diagnostics des résidus du modèle SARIMA retenu.

9 Prédiction sur l'échantillon de validation

Le modèle $\text{SARIMA}(1, 1, 1)(1, 1, 1)_{12}$ est ensuite utilisé pour prévoir les 24 mois de l'échantillon de validation. Les prévisions sont obtenues sur l'échelle logarithmique, puis transformées avec l'exponentielle pour revenir à l'échelle initiale des ventes.




FIGURE 8 – Pr vision SARIMA sur l' chantillon de validation.

10  valuation des performances

Les indicateurs utilis s sont :

$$MAE = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|,$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2},$$

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right|.$$

Sur l' chantillon de validation, le notebook obtient :

Indicateur	Valeur
MAE	1 191
RMSE	1 339
MAPE	5,64 %

TABLE 5 – Performance du mod le sur la validation.

Comme le MAPE est inf rieur   10 %, le notebook conclut que la pr vision est excellente selon ce crit re.

Date	Réel	Prévision	Erreur abs.	Erreur (%)
Jan 1967	12 700	12 890	190	1,49
Fév 1967	16 900	17 255	355	2,10
Mar 1967	23 500	24 559	1 059	4,50
Avr 1967	26 800	28 342	1 542	5,75
Mai 1967	27 300	28 922	1 622	5,94
Juin 1967	26 100	27 960	1 860	7,13
Juil 1967	19 000	20 265	1 265	6,66
Août 1967	16 000	17 058	1 058	6,61
Sep 1967	14 800	15 454	654	4,42
Oct 1967	17 900	18 490	590	3,30
Nov 1967	16 200	16 807	607	3,74
Déc 1967	15 000	15 565	565	3,77
Jan 1968	13 800	14 256	456	3,30
Fév 1968	18 300	19 034	734	4,01
Mar 1968	25 500	26 982	1 482	5,81
Avr 1968	28 900	31 114	2 214	7,66
Mai 1968	29 500	31 763	2 263	7,67
Juin 1968	28 200	30 640	2 440	8,65
Juil 1968	20 400	22 206	1 806	8,85
Août 1968	17 200	18 699	1 499	8,71
Sep 1968	15 900	16 983	1 083	6,81
Oct 1968	19 200	20 351	1 151	5,99
Nov 1968	17 400	18 485	1 085	6,23
Déc 1968	16 100	17 105	1 005	6,24

TABLE 6 – Valeurs réelles et prévisions sur l'échantillon de validation.

11 Conclusion

On trouve que la série des ventes de voitures possède une tendance croissante et une saisonnalité annuelle marquée. La transformation logarithmique permet de stabiliser l'amplitude des variations, puis les différenciations ordinaire et saisonnière permettent de travailler avec une série stationnaire. La recherche par AIC retient le modèle SARIMA(1, 1, 1)(1, 1, 1)₁₂.

Sur les deux années gardées pour la validation, le modèle donne un MAPE de 5,64 %. Les prévisions suivent correctement le profil saisonnier de la série. Le modèle est donc acceptable pour une présentation de niveau ingénieur : il est cohérent avec la méthode de Box-Jenkins, il respecte les étapes de l'énoncé et il donne une qualité de prévision satisfaisante.