



Module : Séries Chronologiques

Encadré par : Mme Badaoui

Application de la méthode de Box-Jenkins

Prévision des ventes mensuelles de voitures au Québec

Réalisé par :

Ait Bargach Ahmed

Année universitaire 2025–2026

Résumé

Ce rapport applique la méthodologie de Box-Jenkins à une série mensuelle de ventes de voitures au Québec, observée de janvier 1960 à décembre 1968. L'objectif est de construire un modèle de prévision simple, interprétable et validé sur un échantillon test. La série présente une tendance croissante et une saisonnalité annuelle nette. Après transformation logarithmique et différenciations ordinaire et saisonnière, un modèle SARIMA est estimé. Le modèle retenu, $\text{SARIMA}(3, 1, 1)(0, 1, 0)_{12}$, donne une erreur moyenne absolue d'environ 160 ventes sur la période de validation, soit un MAPE proche de 0,73 %.

1 Introduction

Une série chronologique est une suite d'observations ordonnées dans le temps. L'objectif principal du travail demandé est d'appliquer la méthode de Box et Jenkins : visualiser la série, étudier sa tendance et sa saisonnalité, la rendre stationnaire, identifier un modèle à partir des corrélogrammes, estimer ce modèle, valider les résidus puis produire des prévisions.

La démarche suivie reprend les étapes vues dans le cours : description des données, décomposition tendance/saisonnalité, tests de stationnarité, analyse des fonctions d'autocorrélation ACF et PACF, estimation SARIMA, validation et prévision finale.

2 Description des données

La série utilisée contient les ventes mensuelles de voitures au Québec entre janvier 1960 et décembre 1968. Elle contient donc 108 observations mensuelles. La variable étudiée est le nombre de ventes par mois.

Statistique	Valeur
Nombre d'observations	108
Minimum	6 550
Premier quartile	11 300
Médiane	14 493,5
Moyenne	15 396,0
Troisième quartile	18 152
Maximum	29 500

TABLE 1 – Statistiques descriptives de la série.

La figure 1 montre une croissance globale des ventes au cours du temps. On observe aussi une répétition annuelle : les ventes sont généralement plus élevées au printemps et plus faibles au début ou à la fin de certaines années. Cela justifie l'utilisation d'un modèle saisonnier de période $s = 12$.




FIGURE 1 – Série complète des ventes mensuelles.

3 Échantillons d'apprentissage et de validation

Conformément à l'énoncé, les données sont divisées en deux parties. Le modèle est estimé sur la période janvier 1960 – décembre 1966, puis évalué sur janvier 1967 – décembre 1968.

Échantillon	Période	Taille
Apprentissage	1960-01 à 1966-12	84
Validation	1967-01 à 1968-12	24

TABLE 2 – Découpage des données.




FIGURE 2 – Séparation apprentissage / validation.

4 Analyse qualitative

La série présente deux composantes importantes :

- une tendance croissante : le niveau moyen des ventes augmente entre 1960 et 1968 ;

- une saisonnalité annuelle : certains mois reviennent régulièrement avec des niveaux plus élevés.



FIGURE 3 – Profil saisonnier des ventes par année.

La décomposition multiplicative est adaptée car l'amplitude saisonnière augmente avec le niveau de la série. On peut écrire, de manière simplifiée :

$$Y_t = T_t \times S_t \times R_t,$$

où T_t est la tendance, S_t la composante saisonnière et R_t le résidu.




FIGURE 4 – Décomposition multiplicative de la série.

5 Stationnarité

La méthode de Box-Jenkins suppose de travailler sur une série stationnaire. La série brute n'est pas stationnaire : le test ADF ne rejette pas la racine unitaire et le test KPSS rejette l'hypothèse de stationnarité. Comme la saisonnalité semble multiplicative, on applique d'abord une transformation logarithmique. Ensuite, on utilise une différenciation ordinaire et une différenciation saisonnière :

$$Z_t = (1 - B)(1 - B^{12}) \log(Y_t).$$

Série testée	p-value ADF	p-value KPSS
Série brute	0,9886	0,0100
$\log(Y_t)$	0,7168	0,0100
$\Delta \log(Y_t)$	0,0002	0,1000
$\Delta \Delta_{12} \log(Y_t)$	0,0089	0,1000

TABLE 3 – Tests de stationnarité sur l'échantillon d'apprentissage.

Après transformation et différenciations, la série devient stationnaire : la p-value du test ADF est inférieure à 5 % et celle du test KPSS est supérieure à 5 %.




FIGURE 5 – Transformations utilisées pour stabiliser la série.

6 Corrélogrammes ACF et PACF

Les corrélogrammes ACF et PACF sont tracés jusqu'au retard $K = 36$, comme demandé dans l'énoncé. Après différenciation, les autocorrélations deviennent rapidement plus faibles, ce qui confirme que la série transformée est exploitable dans un modèle ARMA/SARIMA. Les premiers retards restent informatifs, ce qui motive la recherche sur de petits ordres p et q .




FIGURE 6 – ACF et PACF de la série transformée stationnaire.

7 Modélisation Box-Jenkins

On estime des modèles SARIMA de la forme :

$$SARIMA(p, 1, q)(P, 1, Q)_{12}.$$

La recherche est volontairement limitée à de petits ordres, afin de garder un modèle interprétable : $p, q \in \{0, 1, 2, 3\}$ et $P, Q \in \{0, 1\}$. Les modèles sont comparés à l'aide du critère AIC, puis vérifiés par les diagnostics des résidus et par la qualité de prévision sur l'échantillon de validation.

Modèle	AIC	BIC	MAPE validation
$SARIMA(3, 1, 1)(0, 1, 0)_{12}$	-261,25	-250,15	0,73 %
$SARIMA(3, 1, 2)(0, 1, 0)_{12}$	-259,26	-245,94	0,72 %
$SARIMA(0, 1, 3)(0, 1, 0)_{12}$	-256,53	-247,71	4,38 %
$SARIMA(0, 1, 3)(1, 1, 0)_{12}$	-256,29	-245,90	4,76 %
$SARIMA(3, 1, 3)(0, 1, 0)_{12}$	-254,82	-239,38	4,53 %

TABLE 4 – Comparaison de quelques modèles candidats.

Le modèle retenu est donc :

$$SARIMA(3, 1, 1)(0, 1, 0)_{12}.$$

Sur la série logarithmique, il s'écrit :

$$(1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3)(1 - B)(1 - B^{12}) \log(Y_t) = (1 + \theta_1 B) \varepsilon_t.$$

8 Validation du modèle

Les résidus doivent ressembler à un bruit blanc : ils ne doivent pas présenter une structure temporelle claire. Les diagnostics graphiques sont globalement satisfaisants. Le test de Ljung-Box à 24 retards donne une p-valeur de 0,587, ce qui ne permet pas de rejeter l'hypothèse d'absence d'autocorrélation globale des résidus. Le retard 12 est légèrement limite, mais le modèle reste très performant en validation et demeure simple à présenter.




FIGURE 7 – Diagnostics des résidus du modèle retenu.

Indicateur	Valeur
MAE	159,99
RMSE	200,89
MAPE	0,73 %

TABLE 5 – Erreurs de prévision sur l'échantillon de validation.

Le graphique de validation montre que les prévisions suivent très bien les observations réelles de 1967 et 1968.




FIGURE 8 – Prévision sur l'échantillon de validation.

9 Pr vision finale

Apr s validation, le mod le est r estim  sur toute la s rie disponible, puis utilis  pour pr voir les ventes mensuelles de l'ann e 1969.




FIGURE 9 – Pr vision finale pour l'ann e 1969.

Mois	Pr�vision	Borne inf. 95 %	Borne sup. 95 %
1969-01	14 844	14 043	15 691
1969-02	19 683	18 472	20 973
1969-03	27 444	25 571	29 455
1969-04	31 076	28 954	33 352
1969-05	31 716	29 550	34 041
1969-06	30 303	28 233	32 525
1969-07	21 927	20 406	23 562
1969-08	18 489	17 177	19 902
1969-09	17 097	15 837	18 457
1969-10	20 645	19 094	22 323
1969-11	18 710	17 285	20 253
1969-12	17 309	15 983	18 746

TABLE 6 – Pr visions finales des ventes pour 1969.

10 Conclusion

La s rie  tudi e pr sente une tendance croissante et une saisonnalit  annuelle nette. La transformation logarithmique, puis les diff renciations ordinaire et saisonni re, permettent d'obtenir une s rie stationnaire. La m thode de Box-Jenkins conduit   retenir un mod le SARIMA(3, 1, 1)(0, 1, 0)₁₂. Les r sultats sur la p riode de validation sont tr s satisfaisants, avec un MAPE inf rieur   1 %. Les pr visions finales pour 1969 conservent le profil saisonnier observ  : niveaux  lev s au printemps, puis baisse vers l' t  et l'automne.

Pour une pr sentation orale, l'id e principale   retenir est simple : la s rie augmente, elle est saisonni re, on la stabilise par logarithme et diff renciations, puis un mod le SARIMA permet de pr voir correctement les deux derni res ann es gard es en validation.